Beursrally 2026 — Development pipeline

Nov 9, 2026 · @jasper

Doel en principe

Het systeem kiest en beheert een portefeuille die het **verwachte prijzengeld** maximaliseert, niet het verwachte rendement. Dat onderscheid bepaalt elke keuze in dit document.

De situatie. Vorig jaar speelden 34.000 deelnemers. Alleen de top 3 per klassement wint iets; plaats 4 en plaats 34.000 leveren allebei €0 op. De rangschikking gebeurt op de portefeuillewaarde op 22 januari 2027 om 22u15, inclusief bonuskapitaal en na kosten.

De doelfunctie.

$$\max_{\pi} \; \mathbb{E}\big[\Pi(V_T)\big], \qquad \Pi(V_T) = \sum_{k=1}^{3} p_k \cdot \mathbf{1}\{\mathrm{rang}(V_T) = k\}$$

waarbij:

- π — de strategie (welke aandelen, wanneer handelen)
- V_T — je portefeuillewaarde op het einde
- $\Pi(\cdot)$ — het prijzengeld als functie van die waarde
- p_k — de prijs voor plaats k
- $\mathbf{1}\{\cdot\}$ — indicator: 1 als de voorwaarde klopt, anders 0

In het studentenklassement is (p_1, p_2, p_3) = (€2.500, €1.500, €1.000); in het algemeen klassement (€10.000, €2.500, €1.500). Je wint maximaal één van beide, dus het totale prijzengeld is het maximum van de twee.

Waarom dit risico beloont. Een gewone belegger heeft een concave nutsfunctie: elke extra euro is iets minder waard, dus risico verlaagt het verwachte nut (Jensen). Π is daarentegen een trapfunctie van je rang. Onder de drempel voor de top 3 is ze in de praktijk convex: verlies kost niets, want je zat al op €0, terwijl een uitschieter naar boven veel oplevert. Daardoor verhoogt extra spreiding je verwachte prijzengeld, net zoals volatiliteit de waarde van een calloptie verhoogt.

Die logica keert om zodra je boven de drempel staat. Dan ligt het deel van de functie dat je kunt verliezen onder je, en wordt risico afbouwen de beste keuze. Het hele systeem draait om dat ene schakelmoment.

Hoofddoel: top 3 in het studentenklassement, met het algemeen klassement als bonus. Het studentenveld is veel kleiner, dus de drempel ligt lager.

Gratis kapitaal, buiten het model. 46 quizvragen × €100 = +€4.600 (+9,2%), plus Finance Avenue op 28 november = +€500 (+1%). Dat is meer dan elk realistisch voordeel uit een rendementsmodel. Elke quizvraag correct beantwoorden heeft de hoogste prioriteit van het hele project.

De pipeline. Zeven stappen: stap 1 tot 5 bouwen de startportefeuille, stap 6 test welke handelsregel het best werkt, stap 7 draait elke beursdag tijdens de wedstrijd.

Vier modellen voeden de startportefeuille; de rollout stuurt elke dag bij



pipeline · 7 stappen

Data voedt drie modellen; samen bepalen ze de startportefeuille. Daarna kiest de validatie de beste regel, en de rollout draait die elke beursdag.

Notatie

Deze symbolen komen in het hele document terug.

Symbool	Betekenis
i, j	index van een aandeel (i = 1, …, N; N ≈ 374)
t	beursdag; T = laatste dag van de wedstrijd
h	horizon in beursdagen
P_{i,t}	koers van aandeel i op dag t, in euro
r_{i,t}	log-rendement van aandeel i op dag t
G_{i}	brutorendement (eindkoers / beginkoers) over de horizon
μ_i	verwacht rendement van aandeel i

Symbool	Betekenis
σ_i	volatiliteit (standaardafwijking van het rendement)
ρ_{ij}	correlatie tussen aandeel i en j
Σ	covariantiematrix van alle aandelen
w_i	gewicht van aandeel i in de portefeuille
V_t	portefeuillewaarde op dag t
D^{(k)}	eindwaarde van de k-de beste concurrent (de drempel)
S, s	aantal simulaties, index van één simulatie

Stap 1 — Data

Resultaat: een tabel met 8–10 jaar dagkoersen in euro voor de 374 verhandelbare effecten. Elke volgende stap rekent daarop; een fout hier werkt overal door.

Universum. De effectenlijst van de Beursrally telt 445 effecten: 354 aandelen, 20 ETF's, 69 fondsen en 2 met verouderde koersen (Electronic Arts, InPost). Fondsen vallen af: bij verkoop betaal je 1,32% belasting en hun prijs (de netto-inventariswaarde) wordt maar één keer per dag bepaald. Wat overblijft, 374 aandelen en ETF's, staat in `universe.csv` met ISIN en Yahoo-ticker.

Waarom 8–10 jaar? Voor volatiliteit volstaat een jaar data, maar een verwacht rendement schatten vergt veel meer. De standaardfout van een gemiddeld rendement daalt maar met de wortel van de looptijd: met σ = 50% per jaar is de onzekerheid na 2 jaar nog ±35% per jaar. Bovendien bevat een langere periode verschillende marktregimes (stijgende, dalende en zijwaartse markten), zodat stap 2 niet op één soort markt afgesteld wordt.

Bron. Yahoo Finance via de Python-bibliotheek `yfinance`: gratis en betrouwbaar genoeg voor dagkoersen. Recente beursintroducties (Cerebras, SpaceX, Quantinuum, SK hynix ADR) worden via hun ISIN opgezocht. Koersen van het Beursrally-platform gebruiken we niet: scrapen en opslaan in een databank zijn volgens het reglement verboden.

Bewerkingen.

1. **Alleen voor splitsingen gecorrigeerde koersen** ophalen: in yfinance de gewone `Close`, niet `Adj Close`. Bij een splitsing van 1 naar 10 daalt de koers met 90% zonder dat er iets verloren gaat; die sprong halen we weg. Dividenden corrigeren we bewust niet: de Beursrally keert geen dividenden uit, dus op de ex-dividenddatum verlies je in

de wedstrijd echt de koersdaling. `Adj Close` zou die daling wegpoetsen en het rendement overschatten. Dat geldt ook voor uitkerende ETF's (Dist); bij kapitaliserende ETF's (Acc) zit de herbelegging al in de koers.

2. **Omzetten naar euro.** De portefeuille wordt in euro gewaardeerd, dus een Amerikaans aandeel draagt ook wisselkoersrisico:

```
P^{\mathrm{EUR}}_{i,t} = \frac{P^{\mathrm{USD}}_{i,t}}{X_t}
```

waarbij P^USD_{i,t} de koers in dollar is en X_t de wisselkoers (dollar per euro) op dag t.

3. **Log-rendementen** berekenen:

```
r_{i,t} = \ln\frac{P_{i,t}}{P_{i,t-1}}, \qquad r_{i,t \to t+h} =
\sum_{\tau=t+1}^{t+h} r_{i,\tau}, \qquad G_{i,t \to t+h} = e^{\,r_{i,t\to
t+h}}
```

waarbij r_{i,t} het dagrendement is, r_{i,t→t+h} het rendement over h dagen en G het brutorendement (1,25 = +25%). Log-rendementen tellen gewoon op over de tijd; dat maakt simuleren over meerdere dagen eenvoudig.

4. **Eén kalender.** Amerikaanse en Europese beursdagen vallen niet altijd samen (feestdagen). Ontbrekende koersen vullen we met de vorige koers in, maximaal 3 dagen na elkaar.

Kwaliteitscontrole bij elke update.

- Heeft elk effect een nieuwe koers? Zo niet: melden, niet stilzwijgend de oude gebruiken.
- Is er een dagrendement |r_{i,t}| > ln 1,5? Dan nakijken op een splitsing of een datafout.
- Hoeveel historiek heeft elk effect? Minder dan 60 beursdagen → uitgesloten van de selectie.

Bekend probleem: survivorship bias. De lijst is die van vandaag, en een aandeel staat er vaak op omdat het recent opviel, meestal door sterk te stijgen. Formeel geldt dan:

```
\mathbb{E}\big[r_{i,t} \mid i \in \text{lijst van vandaag}\big] >
\mathbb{E}\big[r_{i,t}\big] \quad \text{voor } t \text{ in het verleden}
```

Een backtest op deze lijst overschat dus de rendementen, en vooral momentumstrategieën. We melden dat bij elk testresultaat, en waar mogelijk testen we ook op een bredere lijst die niet achteraf gekozen is (bv. alle aandelen uit de S&P 500 en de STOXX 600).

Stap 2 — Rendementsmodellen testen

Resultaat: per horizon h een getest verwacht rendement $\hat{\mu}_i$ per aandeel, of de onderbouwde vaststelling dat geen enkel model beter doet dan "elk aandeel hetzelfde". Beide uitkomsten zijn bruikbaar: de tweede betekent dat de strategie volledig op risico en het klassement steunt.

De vraag. Kunnen we op dag t voorspellen welke aandelen de komende h dagen relatief beter zullen doen, met genoeg precisie om de transactiekosten terug te verdienen? We testen dat voor $h \in \{1, 3, 5, 10, 20, 48\}$ beursdagen. De horizon bepaalt hoe vaak herbalanceren zinvol kan zijn.

De kandidaat-modellen

Model	Idee	Voorspelling $\hat{\mu}_{i,t}$
Gelijk (benchmark)	Niemand kan het voorspellen	Dezelfde waarde voor elk aandeel
CAPM	Meer marktrisico, meer rendement	$\hat{\beta}_i \times$ marktpremie
Momentum	Winnaars blijven even winnen	$\kappa_h \times$ score op 6-maandsrendement
Kortetermijnomkeer	Wie een week hard daalde, veert terug	$\kappa_h \times$ score op −(weekrendement)
ML	Combinatie van veel kenmerken	f_θ(kenmerken van aandeel i)

CAPM.

$$\hat\mu_{i,t} = \hat\beta_{i,t}\,\big(\mathbb{E}[R_m]-R_f\big)\frac{h}{252}, \qquad \hat\beta_{i,t} = \frac{\widehat{\mathrm{Cov}}(r_i, r_m)}{\widehat{\mathrm{Var}}(r_m)}$$

waarbij $\hat{\beta}_{i,t}$ de gevoeligheid van aandeel i voor de markt is (geschat op de 252 dagen vóór t), r_m het marktrendement (MSCI World), $E[R_m] - R_f$ de marktpremie per jaar (≈ 5%) en $h/252$ de omrekening naar de horizon. Empirisch is het verband tussen β en rendement zwak of zelfs omgekeerd (de *low-beta anomaly*); daarom testen we het in plaats van het aan te nemen.

Momentum.

$$m_{i,t} = \ln\frac{P_{i,t-21}}{P_{i,t-126}}, \qquad z_{i,t} = \frac{m_{i,t} - \bar m_t}{s_t(m)}, \qquad \hat\mu_{i,t} = \kappa_h\, z_{i,t}$$

waarbij m_{i,t} het rendement van maand −6 tot maand −1 is (de laatste maand wordt overgeslagen omdat die vaak omkeert), m̄_t en s_t(m) het gemiddelde en de standaardafwijking over alle aandelen op dag t, z_{i,t} de gestandaardiseerde score en κ_h de schaalfactor. κ_h schatten we met een cross-sectionele regressie per datum (Fama-MacBeth):

```
r_{i,t\to t+h} = a_t + \kappa_{h,t}\, z_{i,t} + \varepsilon_{i,t}, \qquad
\hat\kappa_h = \frac{1}{|\mathcal{T}|}\sum_{t\in\mathcal{T}} \hat\kappa_{h,t}
```

met a_t het gemiddelde rendement op dag t, ε_{i,t} de fout en 𝒯 de verzameling trainingsdatums. Kortetermijnomkeer werkt identiek, met m_{i,t} = −r_{i,t−5→t}.

ML. Per aandeel en dag een vector kenmerken x_{i,t}: momentum over 5, 20, 60 en 126 dagen, β, volatiliteit over 20 en 60 dagen, relatieve sterkte tegenover de sector en volumeverandering. Het doel is het rendement *tegenover het gemiddelde* van die dag, y_{i,t} = r_{i,t→t+h} − r̄_{t→t+h}, zodat het model leert welke aandelen beter doen en niet hoe de hele markt beweegt. Twee modellen:

```
\text{Ridge:}\quad \hat\theta = \arg\min_{\theta} \sum_{(i,t)\in\text{train}}
\big(y_{i,t} - x_{i,t}^{\top}\theta\big)^2 + \lambda \lVert\theta\rVert_2^2
```

waarbij θ de gewichten van de kenmerken zijn en λ de sterkte van de regularisatie (grotere λ trekt de gewichten naar nul). Het tweede model is LightGBM, een ensemble van beslissingsbomen dat ook niet-lineaire verbanden en interacties vangt. Hyperparameters (λ, diepte van de bomen, leersnelheid) worden alleen op de validatieperiode gekozen.

Walk-forward-validatie

Op elk beslismoment t mag een model alleen trainen op informatie die toen bekend was:

```
\mathcal{D}^{\text{train}}_t = \big\{(x_{i,\tau},\, y_{i,\tau}) : \tau \le t
- h\big\}
```

De doelvariabele y_{i,τ} gebruikt rendementen tot τ + h. Zonder de voorwaarde τ ⩽ t − h (het *embargo*) zou het model rendementen van na t zien. We hertrainen elke maand en voorspellen elke week. De periode 2017–2021 dient om modellen en instellingen te kiezen; 2022–2026 is de testperiode en wordt één keer bekeken, aan het einde.

Toets A — voorspellen ze beter dan "gelijk"?

```
R^2_{OS} = 1 - \frac{\sum_{i,t}\big(r_{i,t\to t+h} - \hat\mu_{i,t}\big)^2}
{\sum_{i,t}\big(r_{i,t\to t+h} - \bar\mu_{t}\big)^2}
```

waarbij de som loopt over alle aandelen i en testdatums t, $\hat{\mu}_{i,t}$ de voorspelling van het model is en $\bar{\mu}_t$ de voorspelling van "gelijk". $R^2_{OS} > 0$ betekent: kleinere voorspelfouten dan zonder informatie. Of dat significant is, toetsen we met Diebold-Mariano:

$$d_t = \frac{1}{N_t}\sum_i \Big[\big(r_{i,t\to t+h}-\bar\mu_t\big)^2 - \big(r_{i,t\to t+h}-\hat\mu_{i,t}\big)^2\Big], \qquad DM = \frac{\bar d}{\widehat{SE}_{NW}(\bar d)}$$

waarbij d_t de winst in kwadratische fout op datum t is, gemiddeld over de N_t aandelen, en SE_NW een Newey-West-standaardfout die rekening houdt met de overlap tussen opeenvolgende horizonnen. Door eerst per datum te middelen, tellen fouten van aandelen op dezelfde dag (die sterk samenhangen) niet als onafhankelijke waarnemingen.

Toets B — rangschikken ze goed?

$$IC_t = \rho_S\big(\hat\mu_{\cdot,t},\; r_{\cdot,t\to t+h}\big), \qquad \overline{IC} = \frac{1}{|\mathcal{T}|}\sum_t IC_t, \qquad t_{IC} = \frac{\overline{IC}}{\widehat{SE}_{NW}(\overline{IC})}$$

waarbij ρ_S de Spearman-rangcorrelatie is tussen voorspelde en gerealiseerde rendementen van alle aandelen op datum t. Een model kan de niveaus slecht voorspellen maar de volgorde goed; voor aandelen kiezen telt vooral de volgorde. Voor "gelijk" bestaat de IC niet (alle voorspellingen zijn gelijk), daarom is toets A nodig als vergelijking.

Toets C — verdienen ze de kosten terug?

Een wissel (verkopen + kopen) kost $c \approx 2 \times 0{,}35\% + €10 / €4.900 \approx 0{,}9\%$. Koop je de aandelen bovenaan de ranking, dan is je verwachte voorsprong ongeveer:

$$\mathbb{E}[\text{voorsprong}] \approx IC_h \cdot \sigma_{cs,h} \cdot z, \qquad IC^{\min}_h = \frac{c}{\sigma_{cs,h}\, z}$$

waarbij $\sigma_{cs,h}$ de spreiding van rendementen tussen aandelen over horizon h is, $z \approx 1{,}5$ de gemiddelde gestandaardiseerde score van de gekozen aandelen (bij de beste ~15%) en IC^{min}_h de IC die nodig is om quitte te spelen. Omdat $\sigma_{cs,h}$ groeit met $\sqrt{h}$, worden korte horizonnen veel strenger:

Horizon h	$\sigma_{cs,h}$ (volatiele aandelen, ruw)	IC^{min}_h
3 dagen	≈ 7%	≈ 0,09
5 dagen	≈ 10%	≈ 0,06
20 dagen	≈ 20%	≈ 0,03

Horizon h	σ_{cs,h} (volatiele aandelen, ruw)	IC^min_h
48 dagen	≈ 30%	≈ 0,02

Ter vergelijking: professionele modellen halen meestal een IC van 0,02 tot 0,05.

Beslisregel

Een model telt mee als het $R^2_OS > 0$ haalt (toets A, significant) en in stap 6 vaker boven de drempel eindigt. Ook dan gebruiken we een afgezwakte voorspelling:

```
\hat\mu^{\text{gebruikt}}_{i,t} = w\,\hat\mu^{\text{model}}_{i,t} + (1-
w)\,\bar\mu_t, \qquad w = \max\!\Big(0,\; 1 - \frac{1}{t_{IC}^2}\Big)
```

waarbij w het vertrouwen in het model is, afhankelijk van de t-waarde van de IC (een James-Stein-achtige shrinkage). Bij $t_IC = 1$ is $w = 0$, bij $t_IC = 2$ is $w = 0{,}75$ en bij $t_IC = 3$ is $w \approx 0{,}89$. Aandelen met een korte historiek krijgen een kleinere w, omdat hun schatting onzekerder is.

Hoeveel kunnen we eigenlijk meten?

```
\widehat{SE}(\overline{IC}) \approx \frac{s(IC_t)}{\sqrt{N_{\text{eff}}}},
\qquad s(IC_t) \approx 0{,}15
```

waarbij s(IC_t) de spreiding van de IC tussen datums is en N_eff het aantal onafhankelijke waarnemingen. Over 8 jaar zijn er maar ongeveer 40 niet-overlappende vensters van 48 dagen: SE ≈ 0,024, dus een echte IC van 0,03 geeft t ≈ 1,3 en is niet van ruis te onderscheiden. Op weekhorizon zijn er ongeveer 400 vensters: SE ≈ 0,0075, en dan is zo'n effect wel meetbaar.

Stap 3 — Risicomodel

Resultaat: per aandeel een actuele volatiliteit, een stabiele covariantiematrix Σ, een indeling in thema's en een generator die duizenden realistische toekomstscenario's maakt. In een toernooi bepaalt risico het resultaat het sterkst, en gelukkig kunnen we het veel beter schatten dan verwacht rendement.

Waarom risico wel schatbaar is. Met dagdata zie je een variantie al na enkele maanden redelijk scherp: elke dag levert een nieuwe waarneming van r^2. Een gemiddeld rendement wordt daar niet preciezer van, want alleen de totale looptijd telt (Merton, 1980). Dat is de reden waarom het model sterk op σ en ρ leunt en voorzichtig is met μ.

Volatiliteit en covariantie

Recente dagen wegen zwaarder, omdat volatiliteit in clusters komt (rustige en woelige periodes wisselen elkaar af). Exponentieel gewogen (EWMA):

$$\sigma^2_{i,t} = \lambda\,\sigma^2_{i,t-1} + (1-\lambda)\,r^2_{i,t-1}, \qquad \Sigma_t = \lambda\,\Sigma_{t-1} + (1-\lambda)\,\mathbf{r}_{t-1}\mathbf{r}_{t-1}^{\top}$$

waarbij λ de vervalfactor is, σ²_{i,t} de variantie van aandeel i op dag t en **r**_{t−1} de vector met alle rendementen van gisteren. De halfwaardetijd is ln 0,5 / ln λ: 11 dagen bij λ = 0,94 en 23 dagen bij λ = 0,97. We kiezen λ ∈ {0,94; 0,97; 0,99} op basis van het voorspellen van de volatiliteit van de volgende 10 dagen, buiten de trainingsperiode.

Shrinkage. Met N ≈ 374 aandelen en zo'n 250 dagen data heeft Σ meer onbekenden dan waarnemingen; de gewone schatter is dan singulier en ruizig. Daarom trekken we hem naar een eenvoudig doel (Ledoit-Wolf):

$$\hat\Sigma = \delta\, F + (1-\delta)\, S, \qquad F_{ij} = \bar\rho\, \hat\sigma_i \hat\sigma_j \;(i\neq j), \quad F_{ii} = \hat\sigma_i^2$$

waarbij S de steekproefcovariantie is, F een doelmatrix waarin alle paren dezelfde gemiddelde correlatie ρ̄ hebben, en δ ∈ [0, 1] de mate van shrinkage, die Ledoit-Wolf uit de data schat.

Volatiliteit voorspellen voor de wedstrijdperiode

Wat telt, is de volatiliteit *tijdens de wedstrijd*, niet die van de afgelopen weken. Volatiliteit keert terug naar een langetermijnniveau: een aandeel dat net heel rustig of heel wild was, beweegt de komende weken waarschijnlijk richting zijn gemiddelde. Een GARCH(1,1)-model per aandeel vangt dat:

$$\sigma^2_{i,t+1} = \omega_i + \alpha_i\, r^2_{i,t} + \beta_i\, \sigma^2_{i,t}, \qquad \bar\sigma_i^2 = \frac{\omega_i}{1-\alpha_i-\beta_i}$$

waarbij ω_i, α_i en β_i parameters zijn die per aandeel geschat worden (met $\alpha_i + \beta_i < 1$), $r^2_{i,t}$ het gekwadrateerde rendement van vandaag en $\bar\sigma_i^2$ het langetermijnniveau. De voorspelling j dagen vooruit en het gemiddelde over de H dagen van de wedstrijd:

$$\mathbb{E}_t\big[\sigma^2_{i,t+j}\big] = \bar\sigma_i^2 + (\alpha_i+\beta_i)^{\,j-1}\big(\sigma^2_{i,t+1} - \bar\sigma_i^2\big), \qquad \hat\sigma^{(H)}_i = \sqrt{\frac{1}{H}\sum_{j=1}^{H} \mathbb{E}_t\big[\sigma^2_{i,t+j}\big] + \frac{1}{H}\sum_{e \in E_i} \delta_{i,e}^2}$$

waarbij $\alpha_i + \beta_i$ bepaalt hoe snel de volatiliteit naar haar gemiddelde terugkeert, $\hat{\sigma}_i^{(H)}$ de voorspelde dagvolatiliteit voor de wedstrijdperiode is, E_i de verzameling bekende gebeurtenissen voor aandeel i tijdens de wedstrijd (vooral kwartaalcijfers) en $\delta_{i,e}$ de typische koerssprong rond zo'n gebeurtenis, geschat op vorige publicaties.

Impliciete volatiliteit voor Amerikaanse aandelen. Optieprijzen bevatten de verwachting van de markt over de volatiliteit tot de vervaldag. Die informatie is vooruitkijkend en omvat al bekende gebeurtenissen zoals kwartaalcijfers. In de literatuur voorspelt impliciete volatiliteit meestal beter dan modellen op historische koersen (o.a. Christensen & Prabhala, 1998; Blair, Poon & Taylor, 2001), al is dat bewijs het sterkst voor indexopties.

Geen enkele optie vervalt precies op 22 januari 2027. We interpoleren daarom de totale variantie tussen de twee vervaldagen rond het einde van de wedstrijd, met at-the-money-opties:

```
\nu(\tau) = \sigma^2_{IV}(\tau)\,\tau, \qquad \nu(\tau_T) = \nu(\tau_1) +
\frac{\tau_T - \tau_1}{\tau_2 - \tau_1}\big(\nu(\tau_2) - \nu(\tau_1)\big),
\qquad \sigma_{IV,i} = \sqrt{\frac{\nu(\tau_T)}{\tau_T}}
```

waarbij τ de looptijd in jaren is, $\sigma_IV(\tau)$ de impliciete jaarvolatiliteit van de at-the-money-optie met looptijd τ, $\nu(\tau)$ de totale variantie tot de vervaldag, τ_1 en τ_2 de vervaldagen net vóór en net na het einde van de wedstrijd, en τ_T de resterende looptijd van de wedstrijd.

Impliciete volatiliteit ligt gemiddeld iets boven de volatiliteit die zich daarna echt voordoet: optiekopers betalen een risicopremie. We combineren ze daarom met de GARCH-voorspelling:

```
\hat\sigma^{2\,(H)}_i = \lambda\,\big(c\,\sigma_{IV,i}\big)^2\frac{1}{252} +
(1-\lambda)\,\hat\sigma^{2\,(H)}_{i,\text{GARCH}}
```

waarbij $c \approx 0{,}9$ de correctie voor die risicopremie is, 1/252 de omzetting van jaar- naar dagvariantie, $\lambda \approx 0{,}7$ het gewicht van de impliciete volatiliteit en $\hat{\sigma}^{2(H)}_GARCH$ de GARCH-voorspelling. c en λ komen uit de literatuur, niet uit een eigen schatting: historische optiedata zijn niet gratis, dus backtesten kan niet. Twee details:

- De extra variantie voor kwartaalcijfers ($\delta_{i,e}$) tellen we alleen bij de GARCH-component op; de impliciete volatiliteit bevat ze al, anders tellen we ze dubbel.
- We gebruiken alleen opties met voldoende open interest en een redelijke spread. Zonder bruikbare opties valt het aandeel terug op GARCH, net als alle Europese aandelen.

Tijdens de wedstrijd slaan we elke dag een momentopname van de impliciete volatiliteiten op (van Yahoo, niet van het Beursrally-platform). Zo bouwen we zelf een historiek op om c en λ achteraf te evalueren.

Keuze van het model. We vergelijken GARCH(1,1) met de EWMA hierboven op hun voorspelling van de gerealiseerde variantie over de volgende 48 dagen, buiten de trainingsperiode, met het QLIKE-verlies:

$$\mathrm{QLIKE} = \frac{1}{n}\sum \Big(\frac{\sigma^2_{\text{gerealiseerd}}}{\hat\sigma^2} - \ln\frac{\sigma^2_{\text{gerealiseerd}}}{\hat\sigma^2} - 1\Big)$$

QLIKE is 0 bij een perfecte voorspelling en weegt het onderschatten van volatiliteit zwaarder dan het overschatten. Het model met het laagste QLIKE wordt de standaard. Voor aandelen met minder dan een jaar historiek valt GARCH vaak instabiel uit; daar gebruiken we EWMA.

Covariantie voor de wedstrijdperiode. We combineren de voorspelde volatiliteiten met de correlaties uit de Ledoit-Wolf-schatter:

$$\hat\Sigma^{(H)} = \hat D^{(H)}\, \hat R\, \hat D^{(H)}, \qquad \hat D^{(H)} = \mathrm{diag}\big(\hat\sigma^{(H)}_1, \dots, \hat\sigma^{(H)}_N\big)$$

waarbij $\hat{R}$ de correlatiematrix is die bij $\hat{\Sigma}$ hoort en $D^{(H)}$ een diagonaalmatrix met de voorspelde volatiliteiten. Alle volgende stappen — de scenario's, de kandidatenselectie en de optimalisatie — gebruiken deze $\hat{\sigma}_i^{(H)}$, niet de historische volatiliteit.

Portefeuillerisico

$$\sigma_p = \sqrt{w^{\top}\Sigma\, w}$$

waarbij w de vector met portefeuillegewichten is. Voor n gelijke posities ($w_i = 1/n$), allemaal met volatiliteit σ en onderlinge correlatie ρ:

$$\sigma_p^2 = \frac{1}{n^2}\Big[n\sigma^2 + n(n-1)\rho\sigma^2\Big] = \sigma^2\Big(\rho + \frac{1-\rho}{n}\Big)$$

ρ	σ_p / σ bij n = 10	Betekenis
0	0,32	Spreiding haalt 68% van het risico weg
0,3	0,59	
0,6	0,80	Bijna alle risico blijft
1	1,00	Tien keer hetzelfde aandeel

De 10%-limiet dwingt tot minstens 10 posities. Correlatie is dus de enige manier om het risico van de portefeuille dicht bij dat van de afzonderlijke aandelen te houden.

Thema's

Hiërarchische clustering groepeert aandelen die samen bewegen. Als afstand nemen we:

```
d_{ij} = \sqrt{2\,(1-\rho_{ij})}
```

waarbij d_{ij} = 0 voor perfect samen bewegende aandelen en 2 voor perfect tegengestelde. Deze afstand voldoet aan de driehoeksongelijkheid, wat clustering stabiel maakt. Met *average linkage* en een snede bij een gemiddelde correlatie van ongeveer 0,35 ontstaan groepen zoals AI-infrastructuur, crypto, kwantumcomputing en geheugenchips. De optimalisator kan zo bewust kiezen voor één thema of voor een mix.

Scenario's genereren

Toekomstige rendementen trekken we uit de echte historiek met een **block bootstrap**: blokken van b = 5 opeenvolgende dagen, voor alle aandelen tegelijk. Zo blijven dikke staarten, crashes waarin alles samen daalt en volatiliteitsclusters behouden, die een normale verdeling zou missen. Voor een horizon van H dagen:

```
R_{i,s} = \sum_{k=1}^{\lceil H/b\rceil} \sum_{u=0}^{b-1} \tilde
r_{i,\,\tau_{k,s}+u}, \qquad G_{i,s} = e^{R_{i,s}}
```

waarbij s de simulatie is, τ_{k,s} de willekeurige startdag van blok k, r̃ het aangepaste historische rendement (hieronder) en G_{i,s} het brutorendement van aandeel i in simulatie s.

De historische rendementen passen we op twee punten aan:

```
\tilde r_{i,t} = \kappa_i\big(r_{i,t} - \bar r_i\big) - \tfrac12 \kappa_i^2
s_i^2 + \frac{\hat\mu_i}{h}, \qquad \kappa_i =
\mathrm{clip}\Big(\frac{\hat\sigma^{(H)}_{i}}{s_i},\; 0{,}5,\; 2\Big)
```

waarbij r̄_i en s_i het gemiddelde en de standaardafwijking van het dagrendement in de historiek zijn, κ_i de schaalfactor die de historische volatiliteit s_i omzet naar de voorspelde volatiliteit voor de wedstrijdperiode $\hat\sigma_i^{(H)}$ (begrensd tussen 0,5 en 2 tegen uitschieters in de schatting), en μ̂_i/h het verwachte dagrendement uit stap 2. De term $-\tfrac{1}{2}\kappa^2 s^2$ zorgt dat E[G_i] = e^{μ̂_i H/h}, precies het verwachte rendement uit stap 2 geschaald naar de simulatiehorizon, en niet hoger: zonder die correctie zou elk volatiel aandeel automatisch een hoger verwacht rendement krijgen, wat het model zou bevoordelen zonder reden.

Stap 4 — Concurrentiemodel

Resultaat: in elke gesimuleerde markt s de eindwaarden van de beste drie concurrenten, D^{(1)}_s, D^{(2)}_s en D^{(3)}_s, apart voor het algemeen en het studentenklassement. Dat zijn de drempels die je moet halen.

Waarom de concurrentie simuleren?

Je prijzengeld hangt niet af van je eigen rendement, maar van je rendement tegenover de top 3. Die drempel ligt niet vast: hij beweegt mee met de markt. Stijgen AI-aandelen 40%, dan stijgen de AI-gokkers mee en ligt de top 3 hoger; dalen ze, dan ligt de drempel lager.

Formeel: je wint als $V_T - D^{(3)} > 0$. Benader je V_T en $D^{(3)}$ als normaal verdeeld, dan:

$$P\big(V_T > D^{(3)}\big) \approx \Phi\!\left(\frac{\mathbb{E}[V_T] - \mathbb{E}[D^{(3)}]}{\sqrt{\mathrm{Var}(V_T) + \mathrm{Var}(D^{(3)}) - 2\,\mathrm{Cov}(V_T, D^{(3)})}}\right)$$

waarbij Φ de standaardnormale verdelingsfunctie is, en $\mathrm{Cov}(V_T, D^{(3)})$ aangeeft hoe sterk jouw resultaat en de drempel samen bewegen.

De covariantie doet hier het werk:

- **Je staat achter** (teller negatief). Dan wil je een grote noemer: een **lage** covariantie, dus andere aandelen dan de leiders. Zit je in hetzelfde thema, dan stijg je mee als het goed gaat, maar steek je hen nooit voorbij.
- **Je staat voor** (teller positief). Dan wil je een kleine noemer: een **hoge** covariantie, dus dezelfde aandelen als je achtervolgers. Wat hen helpt, helpt jou ook, en je voorsprong blijft staan.

Een vaste drempel ("haal +40%") zet de covariantie op nul en mist dat volledig. Alleen door de concurrenten in dezelfde gesimuleerde markten te laten spelen, ziet het model hoe vaak je echt boven hen uitkomt.

Archetypes

Voor de start kennen we de andere spelers niet. We simuleren daarom een veld van M spelers (M = 34.000 voor het algemeen klassement), elk met een type:

Type	Portefeuille	Belegd deel a_m	Kans per quizvraag	Ruis door handelen σ_ε
Casual	10–15 bekende aandelen	60–100%	Beta(4, 3)	4%

Type	Portefeuille	Belegd deel a_m	Kans per quizvraag	Ruis door handelen σ_ε
ETF	10 ETF's	85–100%	Beta(4, 3)	2%
Momentum	10–12 uit de top 50 op 6-maandsrendement	90–100%	Beta(8, 2)	6%
Gokker	10 uit de top 40 op volatiliteit, vaak één thema	95–100%	Beta(8, 2)	9%
Inactief	Weinig belegd	0–30%	Beta(1, 6)	1%

De eindwaarde van speler m in simulatie s:

$$V^{(m)}_{T,s} = V_0\Big(1 - a_m + a_m \sum_{i} w^{(m)}_i\, G_{i,s}\Big)\, e^{\varepsilon_{m,s}} + \sum_{b} Q_{m,b}\, G^{(m)}_{s}(t_b, T), \qquad \varepsilon_{m,s} \sim \mathcal{N}(0, \sigma_{\varepsilon,m}^2)$$

waarbij V_0 = €50.000 het startkapitaal is, a_m het belegde deel van speler m, $w_i^{(m)}$ het gewicht van aandeel i bij speler m, $G_{i,s}$ het brutorendement uit stap 3, $\varepsilon_{m,s}$ de ruis omdat de speler tussendoor handelt, en $Q_{m,b}$ het bonuskapitaal dat speler m in schijf b ontvangt en meteen in zijn portefeuille belegt (quiz: een binomiaal aantal juiste antwoorden × €100; Finance Avenue: eventueel €500 begin december), met $G^{(m)}_s(t_b, T)$ het brutorendement van zijn portefeuille van t_b tot het einde. Zo behandelen we het bonusgeld van de concurrenten op dezelfde manier als het jouwe (stap 5).

De drempels zijn dan de hoogste waarden uit het veld (orde-statistieken):

$$D^{(k)}_s = V^{(m)}_{T,s} \text{ van de } k\text{-de beste speler in simulatie } s, \qquad k = 1, 2, 3$$

Omdat elke speler in dezelfde markt s speelt als jij, krijgen de drempels vanzelf de juiste covariantie met jouw resultaat.

Kalibratie. Veldgrootte 34.000 (vorig jaar). Het aantal studenten kennen we nog niet; voorlopig 2.000–3.000. De mix van types stellen we zo af dat de winnaar gemiddeld over alle gesimuleerde markten rond +40% uitkomt. Vorig jaar was dat +33,5%; we nemen bewust een strengere drempel om niet te optimistisch te zijn. We testen ook gevoeligheid voor een sterkere en zwakkere markt.

Formeel kiezen we de verdeling over de types, θ, zodat:

$$\frac{1}{S}\sum_{s=1}^{S} \frac{D^{(1)}_s(\theta)}{V_0} - 1 \approx 0{,}40$$

waarbij D^{(1)}_s(θ) de winnende eindwaarde in simulatie s is bij verdeling θ. Als gevoeligheidstest herhalen we alles met een doel van +30% en +55%. Verandert de gekozen portefeuille daarbij sterk, dan is de keuze niet robuust.

Tijdens de wedstrijd: waarom de top 10 invullen? Voor de start kennen we de concurrentie alleen via de archetypes, een ruwe schatting. Tijdens de wedstrijd zie je in het klassement wie voorstaat en welke aandelen die spelers hebben. Dat is veel betere informatie, om drie redenen:

1. **De top 3 op het einde komt meestal uit de huidige top.** Hoe verder de wedstrijd vordert, hoe minder spelers van achteraan nog kunnen inhalen. De echte leiders bepalen dan de drempel, niet het gemiddelde veld.
2. **Hun portefeuilles bepalen hoe de drempel beweegt.** Zitten de leiders in crypto, dan stijgt de drempel als crypto stijgt. Met hun echte aandelen in de simulatie bewegen ze correct mee met de markt.
3. **Het eindspel draait om hen.** Sta je voor, dan kopieer je de aandelen van je achtervolgers; sta je achter, dan kies je net andere. Dat kan de rollout alleen voorstellen als hij weet wat zij hebben.

De portefeuilles vul je met de hand in, want scrapen mag niet. Tien spelers is een haalbare hoeveelheid. Ze zijn met vertraging zichtbaar, dus de simulatie geeft hen extra ruis alsof ze intussen gehandeld hebben. De rest van de 34.000 spelers blijft gesimuleerd met de archetypes.

Stap 5 — Startportefeuille

Resultaat: welke aandelen je koopt en hoeveel, met het hoogste verwachte prijzengeld. De orders gaan in twee schijven de markt in (zie *Opbouw over twee dagen* onderaan).

Het optimalisatieprobleem

```
\max_{w}\; \widehat{\mathbb{E}}\big[\Pi(V_T(w))\big] \quad \text{z.d.d.}
\quad 0 \le w_i \le \bar w, \quad \sum_i w_i \le 1 - c(w), \quad \#\{i : w_i
> 0\} \le 10 \text{ op dag 1}
```

waarbij w de gewichten bij aankoop zijn, w̄ ≈ 9,8% de maximale aankoop per aandeel (10% min een veiligheidsmarge), c(w) het deel dat aan kosten opgaat en de laatste voorwaarde volgt uit 5 orders per dag over 2 dagen.

Waarom niet gewoon de hoogste verwachte rendementen?

Met een normale benadering en drempel D:

$$P(V_T > D) \approx \Phi\!\left(\frac{\mu_p - D}{\sigma_p}\right)$$

waarbij μ_p het verwachte rendement van de portefeuille is, σ_p de volatiliteit ervan en Φ de standaardnormale verdelingsfunctie. Een hoger μ_p helpt altijd. Maar zolang D > μ_p, stijgt de kans ook met σ_p, en vaak veel sterker. Voorbeeld met D = +23% over de hele wedstrijd:

Portefeuille	μ per aandeel	σ per aandeel	ρ	σ_p	P(boven D)
A: rustige aandelen	10%	10%	0	≈ 3%	≈ 0,001%
B: volatiel, één thema	5%	35%	0,6	≈ 28%	≈ 26%

A heeft het dubbele verwachte rendement en haalt de drempel toch bijna nooit.

Je eigen eindwaarde

$$V_{T,s} = \underbrace{V_0 - \sum_{i}\big(A_i(1+f) + F\big)}_{C_0:\ \text{cash na aankoop}} + \sum_i A_i\, G_{i,s}(0, T) + \sum_{b=1}^{B} Q_b\, G^{p}_{s}(t_b, T)$$

waarbij A_i het bedrag is dat je bij de start in aandeel i stopt, f = 0,35% de beurstaks, F = €5 de vaste kost per order, $G_{i,s}(0, T)$ het brutorendement van aandeel i over de hele wedstrijd, en de laatste som het **bonuskapitaal als kasstroom**:

- Q_b — het bonusbedrag dat je op datum t_b belegt, na kosten: het quizgeld van de voorbije week (€100 per juist antwoord, elke beursdag) en eenmalig €500 van Finance Avenue, dat ten laatste op 4 december op je rekening staat;
- t_b — de beleggingsdatum van schijf b: we beleggen het quizgeld wekelijks in één order, want elke order kost €5;
- $G^{p}_{s}(t_b, T)$ — het brutorendement van je portefeuille van t_b tot het einde in simulatie s.

Bonusgeld dat vroeg binnenkomt, belegt dus mee en doet mee aan de spreiding; geld uit de laatste week blijft cash. Daarvoor heeft de simulatie dagelijkse paden nodig en niet alleen eindrendementen; de block bootstrap uit stap 3 levert die al.

De doelfunctie schatten

$$\widehat{\mathbb{E}}[\Pi] = \frac{1}{S}\sum_{s=1}^{S} \max\Big(\Pi^{\text{alg}}(V_{T,s}),\; \Pi^{\text{stud}}(V_{T,s})\Big), \qquad \Pi^{\text{alg}}(v) = \sum_{k=1}^{3} p^{\text{alg}}_k\, \mathbf{1}\{D^{(k)}_s < v \le D^{(k-1)}_s\}$$

waarbij S het aantal simulaties is (≈ 5.000), Π^alg en Π^stud het prijzengeld in het algemeen en studentenklassement, en D^{(0)} = +∞. Je kunt maar één van beide winnen, vandaar het maximum. De simulatiefout is s(Π)/√S; die rapporteren we naast elk resultaat.

Zoekalgoritme

Het zoekalgoritme heeft één doel: de 10 aandelen vinden met de hoogste Ê[Π]. Alle mogelijke combinaties doorrekenen kan niet (uit 60 kandidaten zijn er ongeveer 7,5 × 10¹⁰), dus het zoekt slim. Kandidaten en startpunten kiezen we met een score per aandeel die verwacht rendement en voorspelde volatiliteit combineert:

```
\text{score}_i = \Phi\!\left(\frac{\hat\mu_i - d}{\hat\sigma^{(H)}_i \sqrt{H}}\right)
```

waarbij $\hat{\mu}_i$ het verwachte rendement over de wedstrijd is (stap 2, na afzwakking), d het doelrendement (bv. 23%), $\hat{\sigma}_i^{(H)}\sqrt{H}$ de voorspelde volatiliteit over de H dagen van de wedstrijd (stap 3) en Φ de standaardnormale verdelingsfunctie. De score is de kans dat het aandeel alleen al het doel haalt. Zonder bruikbare voorspelling (w = 0) zijn alle $\hat{\mu}_i$ gelijk en wordt dit een rangschikking op voorspelde volatiliteit; met w > 0 telt de voorspelling mee in verhouding tot haar belang.

1. **Kandidaten**: de ~100 aandelen met de hoogste score_i, met minstens 60 dagen historiek.
2. **Startpunten**: de 10 met de hoogste score; voor elk thema uit stap 3 de 10 met de hoogste score daarbinnen; en een "contrair" startpunt: hoge score, maar lage correlatie met de aandelen die de gokkers in stap 4 het vaakst houden.
3. **Lokaal zoeken** (hill climbing): wissel telkens één aandeel voor een kandidaat en houd de wissel zolang Ê[Π] stijgt. Herhaal tot geen enkele wissel nog verbetert. De startpunten bepalen alleen op welke heuvel je begint te klimmen; waar je eindigt, bepaalt Ê[Π].
4. **Afvlakken tijdens het zoeken.** De echte Π is een trapfunctie; kleine wijzigingen veranderen ze vaak niet en het zoeken zou dan ruis najagen. Tijdens het zoeken gebruiken we:

```
\tilde\Pi(v) = \sum_{k=1}^{3} (p_k - p_{k+1})\; \mathrm{sigm}\!\Big(\frac{v - D^{(k)}_s}{\tau}\Big), \qquad p_4 = 0
```

waarbij sigm(x) = 1/(1 + e^{−x}) een vloeiende stap is en τ ≈ €200 bepaalt hoe vloeiend.

5. **Out-of-sample controle**: de gekozen portefeuille opnieuw scoren op nieuwe simulaties met een nieuw concurrentieveld. Een groot verschil tussen de score tijdens het zoeken en die controle wijst op overfitting op de simulaties.

Concentratieniveaus. We vergelijken expliciet: 10 aandelen uit één thema, uit 2–3 thema's, de 10 volatielste zonder thema, en 12–15 aandelen. Het model beslist welk niveau het best scoort.

Positiegroottes: altijd het maximum?

Kort antwoord: bij de start bijna altijd wel, later niet noodzakelijk.

Waarom het maximum. Zolang de drempel boven je verwachte rendement ligt, stijgt je kans ongeveer met $\sigma_p^2 = w^T \Sigma w$. Dat is een convexe functie van w. Het maximum van een convexe functie over een veelvlak (hier: $0 \leq w_i \leq \bar{w}$ en $\Sigma w_i \leq 1$) ligt altijd op een hoekpunt. De hoekpunten van dit veelvlak hebben elk gewicht op 0 of op $\bar{w}$. Met $\bar{w} \approx 10\%$ betekent dat: 10 posities op het maximum, de rest 0. De vraag "hoeveel" wordt dus de vraag "welke 10".

Wanneer niet.

- **Meer dan 10 aandelen**, bijvoorbeeld als het quizgeld binnenkomt: de 11de positie krijgt wat overblijft.
- **Je staat voor.** Dan ligt de drempel onder je verwachte waarde, wil je σ_p juist omlaag, en wordt de doelfunctie eerder concaaf. Dan kunnen kleinere, gespreide posities beter zijn.
- **Winnaars boven 10%.** De limiet geldt alleen bij aankoop. Een winnaar mag doorgroeien tot 15% of 25% van de portefeuille; je mag hem alleen niet bijkopen. Als je achterstaat, is dat gratis extra concentratie.

Om die gevallen niet uit te sluiten, laat het model gewichten toe op een rooster $w_i \in \{0; 2{,}5\%; 5\%; 7{,}5\%; 9{,}8\%\}$. Zo kiest het zelf voor het maximum of voor iets kleiners.

Opbouw over twee dagen. Je mag maximaal 5 orders per beursdag plaatsen, dus 10 posities kopen duurt minstens 2 dagen. Orders die je in het weekend plaatst, tellen mee voor maandag.

Moment	Orders	Uitvoering
Weekend 14–15 nov	5 aankopen (de 5 belangrijkste posities)	Maandag 16 nov aan de openingskoers
Maandagavond 16 nov	5 aankopen (de overige posities)	Dinsdag 17 nov aan de openingskoers

De 5 belangrijkste posities zijn die met de grootste bijdrage aan het verwachte prijzengeld; het model rangschikt ze. Eén dag met de helft in cash kost weinig: het is 1 van de 48 beursdagen.

Kosten van de opbouw. Per aankoop €5 + 0,35%, dus bij €4.900 per positie:

```
10 \times (5 + 0{,}0035 \times 4.900) \approx 10 \times 22{,}15 = 221{,}50
\text{ euro} \approx 0{,}44\%
```

Marge. Koop elke positie op 9,5–9,8% van de portefeuille. Zo duwt een koerssprong bij de opening een aankoop niet over de 10%-limiet of over je cash heen.

Stap 6 — Strategie valideren

Resultaat: de handelsregel (policy) die het vaakst in de top 3 eindigt, getest in gesimuleerde én historische wedstrijden. De dagelijkse rollout uit stap 7 gebruiken we pas als hij hier wint van eenvoudigere regels; complexiteit moet zich eerst bewijzen.

De regels die we vergelijken

Een policy π is een voorschrift dat op elke dag t, gegeven de toestand x_t (posities, cash, koersen, klassement), een actie kiest: π(x_t) = a_t.

Policy	Voorschrift
π_0 — kopen en vasthouden	Startportefeuille, daarna alleen quizgeld beleggen
π_vast(k) — vaste frequentie	Elke k dagen heroptimaliseren, k ∈ {3, 5, 10}
π_drempel(δ)	Alleen wisselen als de geschatte winst in Ê[Π] groter is dan δ
π_rollout — stap 7	Dagelijks de beste actie kiezen, met ruismarge

Elke policy speelt met én zonder het rendementsmodel uit stap 2. Zo zien we apart wat de voorspellingen opleveren en wat het bijsturen oplevert.

Test 1 — gesimuleerde wedstrijden

We simuleren S volledige wedstrijden van 48 beursdagen, dag per dag, met het concurrentieveld uit stap 4. Elke policy speelt in dezelfde S wedstrijden (common random numbers). Alle regels zitten erin: €5 + 0,35% per order, maximaal 5 orders per dag, maximaal 1 aankoop en 1 verkoop per effect per dag, de 10%-limiet bij aankoop en geen negatieve cash.

```
\hat P_\pi = \frac{1}{S}\sum_{s=1}^{S} \mathbf{1}\{V^{\pi}_{T,s} >
D^{(3)}_s\}, \qquad SE(\hat P_\pi) = \sqrt{\frac{\hat P_\pi(1-\hat P_\pi)}
{S}}
```

waarbij P̂_π de geschatte kans op de top 3 met policy π is en V^π_{T,s} je eindwaarde in wedstrijd s. Twee policies vergelijken we gepaard, want ze speelden dezelfde wedstrijden:

```
\Delta_s = \Pi\big(V^{\pi_1}_{T,s}\big) - \Pi\big(V^{\pi_2}_{T,s}\big),
\qquad t = \frac{\bar\Delta}{s(\Delta)/\sqrt{S}}
```

waarbij Δ_s het verschil in prijzengeld is tussen policy π_1 en π_2 in wedstrijd s. Gepaard vergelijken haalt de gedeelde marktruis weg en maakt kleine verschillen meetbaar.

Test 2 — historische wedstrijden

Elke maand van de afgelopen 8 jaar start een venster van 48 beursdagen: ongeveer 90 vensters. Op de startdag van een venster kiest elke policy met alleen de data van vóór die dag, en daarna speelt ze dag per dag met de echte koersen. Als drempel gebruiken we het gesimuleerde concurrentieveld, toegepast op diezelfde echte koersen.

Test 1 meet hoe goed een policy werkt als onze aannames kloppen; test 2 meet hoe ze werkt in de echte markt, met alles wat de simulatie mist. Een policy kiezen we alleen als ze in beide testen goed scoort.

Maatstaven per policy

- Ê[Π] en P̂(top 3), per klassement, met standaardfout.
- P̂(eindrendement > d) voor een vaste drempel d, bv. +23% op de aandelen.
- Gemiddeld aantal orders en totale kosten.
- Mediaan en 5%- en 95%-kwantiel van het eindrendement.

Waarschuwing. De historische vensters overlappen (gemiddeld 46 van de 48 dagen met hun buur), dus 90 vensters zijn statistisch maar een handvol onafhankelijke waarnemingen. Bovendien heeft de lijst survivorship bias (stap 1). Een kleine voorsprong in test 2 is dus geen bewijs; die moet ook in test 1 overeind blijven.

Stap 7 — Dagelijkse rollout

Resultaat: elke beursdag één advies — niets doen, of maximaal 5 concrete orders — met het effect op je verwachte prijzengeld en de kosten. Je plaatst de orders zelf; automatisch plaatsen mag niet volgens het reglement.

Het probleem formeel

De wedstrijd is een sequentieel beslissingsprobleem (een Markov-beslissingsproces). Op elke dag t kies je een actie a_t op basis van de toestand x_t; de markt bepaalt de volgende toestand; op het einde krijg je Π(V_T). De optimale strategie volgt uit de Bellman-

vergelijking:

$$J^*_t(x_t) = \max_{a \in \mathcal{A}(x_t)} \mathbb{E}\big[J^*_{t+1}(x_{t+1}) \mid x_t, a\big], \qquad J^*_T(x_T) = \Pi(V_T)$$

waarbij J*_t(x) het hoogst haalbare verwachte prijzengeld vanuit toestand x op dag t is en 🟥(x_t) de toegelaten acties. Exact oplossen is onmogelijk: de toestand bevat honderden posities, koersen en concurrenten.

Rollout (Bertsekas) benadert dit. Neem een eenvoudige basisregel π_0, hier "vasthouden tot het einde", en kies elke dag de actie die het best is als je daarna π_0 volgt:

$$\tilde\pi(x_t) = \arg\max_{a \in \mathcal{A}(x_t)} Q_{\pi_0}(x_t, a), \qquad Q_{\pi_0}(x_t, a) = \mathbb{E}\big[\Pi(V_T) \mid x_t,\, a,\, \text{daarna } \pi_0\big]$$

waarbij $\tilde\pi$ de rollout-policy is en $Q_\pi_0(x, a)$ het verwachte prijzengeld van actie a gevolgd door de basisregel. Met exacte Q geldt een verbeteringsgarantie: $\tilde\pi$ doet het minstens even goed als π_0. Omdat we Q schatten met simulaties, vragen we een veiligheidsmarge (hieronder). En omdat de rollout elke dag opnieuw draait, corrigeert hij de aanname "daarna niets meer doen" grotendeels.

Toestand x_t

- Je posities (aantal aandelen per effect) en je cash.
- Het aantal resterende beursdagen T − t.
- De koersen tot gisteren, $\hat\mu$ uit stap 2 en Σ uit stap 3.
- Je eigen waarde en die van de top 10 in je klassement, met hun portefeuilles zoals het klassement ze (met vertraging) toont.

Toegelaten acties 🟥(x_t)

Een actie a is een verzameling orders o = (i, kant, hoeveelheid). Ze moet voldoen aan de wedstrijdregels:

$$|a| \le 5, \qquad \#\{o \in a : o = (i, \text{koop}, \cdot)\} \le 1 \;\text{en}\; \#\{o \in a : o = (i, \text{verkoop}, \cdot)\} \le 1 \;\; \forall\, i, \qquad w_i^{\text{na koop}} \le 10\%, \qquad \text{cash} \ge 0$$

waarbij |a| het aantal orders in de actie is. Een volledige wissel (verkopen + kopen) kost 2 orders, dus per dag zijn er hooguit 2 wissels plus 1 losse order. Verkopen gebeurt in aantal aandelen, kopen kan in euro.

De kandidaat-acties, typisch een paar honderd:

- niets doen;
- 1 of 2 volledige wissels: een positie verkopen, een van de 30 beste kandidaten kopen (stap voor stap opgebouwd: eerst de beste wissel, dan de beste tweede daarbovenop);
- **gedeeltelijk verkopen**: een fractie $\varphi \in \{¼, ½, 1\}$ van een positie, eventueel herbelegd in een andere;
- bijkopen in een positie die onder $\bar{w}$ staat;
- risico verlagen: naar ETF's, rustige aandelen of cash;
- de aandelen van een achtervolger of leider kopen;
- quizgeld beleggen.

Gedeeltelijk of volledig verkopen?

Gedeeltelijk verkopen is niet duurder per euro, wel iets duurder per order. Verkoop je een fractie φ van een positie met waarde A, dan is de relatieve kost:

$$\frac{F + f\,\varphi A}{\varphi A} = f + \frac{F}{\varphi A}$$

waarbij F = €5 de vaste kost, f = 0,35% de beurstaks en φA het verkochte bedrag. Voor φA = €1.000 is dat 0,85%; voor €2.500 0,55%; voor €5.000 0,45%. Onder ongeveer €1.500 wordt de vaste kost dus zwaar; daar laten we geen orders toe.

Welke van de twee beter is, hangt af van je positie:

- **Je staat achter.** Meestal een volledige wissel: je wilt geconcentreerd blijven. Een winnaar gedeeltelijk verkopen is dan bijna altijd fout, want je knipt je beste scenario's af.
- **Je staat voor.** Gedeeltelijk verkopen wordt nuttig: een winnaar die tot 20% van je portefeuille is gegroeid afbouwen naar 10% verlaagt σ_p, en met de opbrengst kun je de aandelen van je achtervolgers kopen (hogere covariantie met de drempel, zie stap 4).
- **Geleidelijk risico afbouwen** in de laatste weken, zonder in één keer van thema te wisselen.

Het is dus niet altijd beter om volledig te verkopen. De rollout rekent beide door en kiest.

Evaluatie van een actie

$$\hat Q(a) = \frac{1}{S}\sum_{s=1}^{S} \Pi\big(V^{a}_{T,s}\big)$$

waarbij V^a_{T,s} je eindwaarde is in gesimuleerd verloop s als je vandaag a uitvoert (inclusief de kosten) en daarna vasthoudt, en S ≈ 5.000. In elk verloop bewegen de top 10 mee met hun echte aandelen, plus ruis omdat ze intussen kunnen handelen; de rest van het veld komt uit stap 4.

Common random numbers. Elke kandidaat-actie krijgt dezelfde S verlopen. Het verschil met niets doen is dan gepaard:

```
\Delta_s(a) = \Pi\big(V^{a}_{T,s}\big) - \Pi\big(V^{\varnothing}_{T,s}\big),
\qquad SE\big(\bar\Delta(a)\big) = \frac{s(\Delta(a))}{\sqrt{S}}
```

waarbij ∅ "niets doen" is. De gedeelde marktruis valt weg, zodat ook kleine verschillen tussen acties betrouwbaar zijn.

Beslisregel

```
a^* = \arg\max_{a \in \mathcal{A}(x_t)} \hat Q(a), \qquad \text{uitvoeren als
} \bar\Delta(a^*) > 2\cdot SE\big(\bar\Delta(a^*)\big), \text{ anders niets
doen}
```

De marge van twee standaardfouten voorkomt dat je op simulatieruis handelt. Omdat we het maximum over honderden acties nemen, is Q̂(a*) licht te optimistisch (winner's curse); daarom herberekenen we a* nog eens op nieuwe simulaties voor we hem adviseren.

Verwacht gedrag

Als stap 2 weinig voorspelkracht vindt, adviseert de rollout in week 1–6 meestal niets doen, behalve dode posities vervangen en quizgeld beleggen. In week 7–10 stuurt hij je risico bij op basis van je plaats: meer risico en andere aandelen dan de leiders als je achterstaat, je achtervolgers kopiëren en winnaars afbouwen als je voorstaat.

Dagelijkse routine (~10 minuten)

1. Quizvraag beantwoorden, na het antwoord opgezocht te hebben.
2. Na de Amerikaanse slotkoers het script draaien; het haalt de koersen op.
3. Je waarde en de waarden en portefeuilles van de top 10 invullen.
4. Het advies nakijken en de orders zelf plaatsen, liefst buiten de beursuren zodat ze aan de openingskoers worden uitgevoerd.
5. De beslissing en de reden noteren in een logboek.

Planning, prioriteiten en beperkingen

Stap 1 tot 5 moeten klaar zijn vóór het weekend van 14–15 november; stap 6 en de rollout bouwen we in de eerste weken van de wedstrijd. In week 1–6 is de rollout nog weinig nodig, vanaf week 7 wel.

De werklijst per stap staat in `Implementatie`.

Fase 1 — voor de start (9–15 november).

- [ ] Stap 1: data voor alle 374 effecten, 8–10 jaar, in euro
- [ ] Stap 2: walk-forward-test van de vijf rendementsmodellen over zes horizonnen
- [ ] Stap 3: risicomodel en thema's
- [ ] Stap 4: concurrentiemodel, afgesteld op 34.000 spelers en +33,5%
- [ ] Stap 5: startportefeuille en orders klaar
- [ ] Proefperiode: orders testen en de portefeuilles van de toppers bekijken
- [ ] Registratie als student nakijken; inschrijven voor Finance Avenue

Fase 2 — tijdens de wedstrijd (16 november – 22 januari).

- [ ] Elke beursdag de quiz
- [ ] Stap 6: gesimuleerde en historische wedstrijden, regel kiezen
- [ ] Stap 7: rollout en dagelijks script
- [ ] Wekelijks: model opnieuw draaien met de resterende dagen

Beperkingen.

- Het concurrentiemodel is een aanname tot we het klassement zien; vooral het aandeel gokkers en hun thema's bepalen het resultaat.
- Survivorship bias in de lijst overschat momentum in elke backtest.
- Verwachte rendementen zijn de onzekerste input; daarom worden ze afgezwakt naar "gelijk".
- Portefeuilles van anderen zien we met vertraging en voeren we met de hand in.
- De winnende score van vorig jaar is één datapunt en hangt sterk af van de markt.

Open vragen.

- Is de +33,5% van vorig jaar inclusief het quizgeld?
- Hoeveel studenten deden mee, en wat haalde de beste student?